



**ECOLE MAROCAINE DES
SCIENCES DE L'INGENIEUR**
Membre de
HONORIS UNITED UNIVERSITIES

S2M CASABLANCA

Cahier des Charges

Système IA de transformation de formations enregistrées en cours e-learning structurés

“Nous ne résumons pas la formation. Nous la transformons.”

Projet	Transformation IA de formations enregistrées en cours e-learning
Structure d'accueil	S2M Casablanca
Présenté par	Hala Sadoumi
Cadre	Stage — 4ème année AI & Data Science, EMSI Casablanca
Encadrant(e)	Mme Firdaous Bazhod

Table des matières

1	Contexte et présentation du projet	2
2	Principe fondamental du projet	2
3	Objectifs du projet	2
3.1	Objectif général	2
3.2	Objectifs spécifiques	2
4	Vision produit et expérience utilisateur	3
4.1	Parcours utilisateur cible	3
4.2	Exemple illustratif	3
4.3	Résultat recherché pour l'apprenant	3
5	Périmètre fonctionnel détaillé	3
5.1	Analyse complète de la vidéo source	3
5.2	Compréhension sémantique du contenu	4
5.3	Structuration pédagogique et chapitrage	4
5.4	Préservation du contenu pédagogique	5
5.5	Génération du script pédagogique	5
5.6	Génération du storyboard visuel	5
6	Exigences relatives au style visuel et à la narration	6
6.1	Style visuel	6
6.2	Narration	6
7	Architecture technique	7
8	Modèles de données	9
8.1	Scène (unité d'analyse de base)	9
8.2	Chapitre	9
8.3	Scène transformée (storyboard)	9
9	Choix technologiques et justification	9
10	Contraintes et hypothèses du projet	10
11	Périmètre du MVP (Minimum Viable Product)	11
12	Critères d'évaluation et d'acceptation	11
13	Gestion de projet et planification	11
13.1	Modèle de cycle de vie retenu	12
13.2	Découpage en sprints	12
13.3	Planning prévisionnel	12
13.4	Outils de pilotage et de suivi	13
13.5	Rituels de suivi	13
13.6	Gestion des risques	14
14	Fonctionnalités futures (hors périmètre du MVP)	14
15	Glossaire	14

1 Contexte et présentation du projet

S2M Casablanca organise régulièrement des sessions de formation interne, réunions pédagogiques et ateliers, enregistrés via Microsoft Teams. Ces enregistrements contiennent une matière pédagogique riche : un intervenant qui s'exprime, des supports PowerPoint partagés à l'écran, du partage d'écran, des démonstrations, des questions de participants, des exemples pratiques et des explications techniques.

Le problème est que ces enregistrements ne sont pas conçus comme du contenu d'apprentissage : ce sont des captures d'un événement en direct. Ils comportent des silences, des répétitions, des hésitations, des digressions, et une présentation visuelle (réunion Teams + diapositives) peu adaptée à un usage pédagogique en différé.

L'objectif de ce stage est de concevoir et développer un système basé sur l'intelligence artificielle capable de transformer automatiquement un enregistrement brut de formation en un cours e-learning complet, structuré et visuellement engageant, comparable en qualité à un cours proposé sur une plateforme telle que Coursera.

2 Principe fondamental du projet

Attention :

Ce projet n'est PAS un projet de résumé vidéo

L'objectif n'est pas de réduire une vidéo d'une heure à une vidéo de dix minutes. L'objectif est de préserver l'intégralité du contenu pédagogique utile, tout en transformant la manière dont ce contenu est présenté à l'apprenant. Si la formation originale dure une heure, le cours transformé peut également durer environ une heure : ce qui change, c'est la structure, la narration, les visuels et la navigation — pas la durée du contenu utile.

Le système doit donc distinguer clairement entre deux notions souvent confondues :

- **La compression** (réduire la durée en supprimant du contenu) — ce n'est PAS l'objectif principal du projet.
- **La transformation** (restructurer, réécrire et réhabiller visuellement le contenu tout en préservant sa valeur pédagogique) — c'est l'objectif central du projet.

3 Objectifs du projet

3.1 Objectif général

Concevoir un système d'IA capable de comprendre le contenu sémantique complet d'un enregistrement de formation, puis de le restructurer et de le transformer automatiquement en un cours e-learning structuré en chapitres, avec une narration professionnelle et des supports visuels générés (graphiques, animations, diagrammes).

3.2 Objectifs spécifiques

1. Extraire et analyser l'intégralité du contenu audio, visuel et textuel (OCR) de l'enregistrement.
2. Construire une représentation multimodale riche associant transcript, contexte visuel et informations de scène.
3. Identifier automatiquement la structure pédagogique du contenu (thèmes, sous-thèmes, chapitres) à partir de ruptures sémantiques, et non de découpages temporels arbitraires.
4. Distinguer le contenu à préserver (explications, définitions, exemples, conclusions) du contenu à nettoyer (hésitations, répétitions, silences).

5. Générer un script pédagogique clair et fidèle au contenu original, sans en dénaturer le sens.
6. Générer un storyboard visuel détaillant, pour chaque scène, la narration, le type de visuel et le texte à l'écran.
7. Produire un cours vidéo transformé complet, avec narration, animations et graphismes, découpé en chapitres navigables.
8. Fournir des métadonnées de chapitrage exploitables par une plateforme d'apprentissage (titres, timestamps, résumés, points clés).

4 Vision produit et expérience utilisateur

4.1 Parcours utilisateur cible

1. L'utilisateur dépose un enregistrement brut (ex. training.mp4, ~1h05).
2. Le système analyse l'intégralité de l'enregistrement (audio, visuel, texte).
3. Le système restitue un cours e-learning complet, structuré en chapitres, avec narration et visuels transformés.
4. L'apprenant ouvre le cours, consulte le sommaire des chapitres, navigue librement, et revient plus tard sur un chapitre précis.

4.2 Exemple illustratif

Entrée : training.mp4 — 1h05 — intervenant, diapositives PowerPoint, partage d'écran, questions de participants, répétitions, silences.

Sortie attendue : un cours structuré, par exemple "Introduction à la sécurité des données", découpé comme suit :

Chapitre	Titre	Timestamps
Chapitre 1	Introduction	00 :00 – 07 :35
Chapitre 2	Risques de sécurité	07 :35 – 18 :20
Chapitre 3	Menaces courantes	18 :20 – 31 :45
Chapitre 4	Méthodes de protection	31 :45 – 44 :10
Chapitre 5	Exemple pratique	44 :10 – 55 :30
Chapitre 6	Points clés à retenir	55 :30 – 01 :02 :00

Chaque chapitre contient le contenu visuel transformé (narration professionnelle, diagrammes animés, icônes, texte à l'écran) plutôt que la capture brute de la réunion Teams et des diapositives.

4.3 Résultat recherché pour l'apprenant

L'apprenant doit avoir le sentiment de suivre un véritable cours en ligne, et non de visionner l'enregistrement d'une réunion. Cette perception constitue le critère de réussite le plus important du projet.

5 Périmètre fonctionnel détaillé

5.1 Analyse complète de la vidéo source

Le système doit analyser l'intégralité de l'enregistrement, sans se limiter à des extraits sélectionnés. Les éléments suivants doivent être extraits :

- **Audio** : Parole, locuteurs, dialogues, pauses, déclarations importantes.

- **Transcript** : Un transcript horodaté doit être généré, associant timestamp, locuteur et contenu.

■ 00 :02 :15 — Intervenant 1

“Aujourd’hui, nous allons voir comment les données clients circulent au sein de l’organisation.”

- **Information visuelle** : Apparition de l’intervenant, diapositives, partage d’écran, démonstrations, éléments visuels importants.
- **OCR** : Extraction du texte présent sur les diapositives PowerPoint, les écrans partagés, les documents et le texte incrusté.
- **Information de scène** : Détection des changements de scène, de diapositive, de locuteur, de transition d’écran et des événements visuels.

Le résultat attendu de cette étape est une représentation multimodale riche de l’ensemble de la vidéo.

5.2 Compréhension sémantique du contenu

Le système doit identifier : les thèmes principaux, les sous-thèmes, les concepts, les définitions, les explications, les exemples, les démonstrations, les arguments, les processus, les faits importants, les conclusions, les questions, les répétitions et les échanges hors sujet.

Point critique du projet :

Le système doit comprendre la relation entre ce que l’intervenant dit (audio/transcript) et ce qui est montré visuellement (diapositive, écran partagé, démonstration) au même instant. Cette mise en correspondance audio-visuelle est au cœur du défi technique du projet.

5.3 Structuration pédagogique et chapitrage

Une fois le contenu compris, le système doit l’organiser selon une structure pédagogique hiérarchique, par exemple :

Cours

Chapitre 1 --- Introduction

Concept A

Concept B

Chapitre 2 --- Le problème

Contexte

Enjeux principaux

Chapitre 3 --- La solution

Fonctionnement

Architecture

Chapitre 4 --- Exemple pratique

Chapitre 5 --- Points clés à retenir

Les frontières entre chapitres doivent être déterminées par des ruptures sémantiques de sujet, et non par un découpage temporel arbitraire (ex. un chapitre toutes les 10 minutes).

5.4 Préservation du contenu pédagogique

Le système doit distinguer trois catégories de contenu :

Catégorie	Traitement	Exemples
Contenu à préserver	Conservé intégralement dans le script transformé	Explications, définitions, exemples, procédures, faits techniques, démonstrations, conclusions
Contenu à nettoyer	Supprimé ou lissé lors de la réécriture	Pauses longues, hésitations (“euh”, “donc voilà”), répétitions accidentelles, interruptions techniques
Contenu à traiter avec discernement	Analysé au cas par cas, potentiellement résumé ou intégré	Questions de participants, discussions, explications redondantes d’un même concept, contradictions, échanges informels

L’objectif n’est pas une compression agressive du contenu, mais la préservation du savoir tout en améliorant l’expérience d’apprentissage.

5.5 Génération du script pédagogique

Le système doit générer un script structuré pour le cours transformé. Ce script doit :

- Préserver le sens de la formation originale
- Rester exact sur le plan factuel
- Suivre la structure en chapitres
- Supprimer les éléments conversationnels superflus
- Améliorer la clarté
- Conserver la terminologie technique
- Relier les idées de manière naturelle

Le script généré ne doit pas être une simple copie du transcript, mais une véritable narration pédagogique dérivée du contenu original.

Exemple

Original :

■ “Euh, donc en gros, ce qu’on fait ici, c’est que, vous voyez sur cette diapositive, on prend les données et puis, du coup, on les déplace...”

Narration transformée :

■ “Le système collecte les données provenant de plusieurs sources et les centralise avant traitement.”

5.6 Génération du storyboard visuel

Pour chaque partie du cours transformé, le système doit déterminer :

- Ce qui est expliqué
- Ce que l’apprenant doit voir
- Le type de visuel approprié

- Le texte à afficher
- Ce qui doit être animé
- Le moment du changement de visuel

Exemple, pour le Chapitre 3 — Comment le système fonctionne :

Scène 01	Narration : “Le système collecte les données de trois sources.” Visuel : trois sources de données animées → flèches → plateforme centrale Texte à l’écran : “3 sources de données”
Scène 02	Narration : “Les données sont ensuite traitées et validées.” Visuel : pipeline de traitement animé Texte à l’écran : “Traitement → Validation”

Ce storyboard constitue le plan de production (le “blueprint”) utilisé pour la génération de la vidéo finale.

6 Exigences relatives au style visuel et à la narration

6.1 Style visuel

La vidéo finale ne doit pas reposer principalement sur :

- Les diapositives PowerPoint brutes
- Les enregistrements de réunion
- La capture webcam
- Les écrans de présentation statiques

Elle doit privilégier :

- Des motion graphics (texte animé, icônes, formes, transitions)
- Des illustrations et métaphores visuelles
- Des diagrammes animés et organigrammes
- Des chronologies (timelines) et graphiques de données
- Des mots-clés mis en évidence à l’écran
- Des captures d’écran uniquement lorsque cela est nécessaire (ex. démonstration logicielle)

Chaque visuel doit avoir une fonction explicative claire ; aucun visuel ne doit être ajouté à des fins purement décoratives.

6.2 Narration

Trois approches doivent être évaluées pour la narration du cours transformé :

Option	Description	Avantage	Limite
1 — Voix originale	Conserver la voix de l'intervenant lorsque c'est pertinent	Authenticité, fidélité au ton original	Qualité audio variable, hésitations à nettoyer
2 — Narration IA (TTS)	Générer la voix à partir du script pédagogique réécrit	Cohérence, clarté, contrôle total du texte	Moins de personnalité, nécessite un moteur TTS de qualité
3 — Hybride	Combiner voix originale sur les passages authentiques et voix IA sur les passages réécrits	Meilleur compromis authenticité / clarté	Complexité de montage et de cohérence tonale accrue

L'approche retenue pour le MVP doit être déterminée en fonction de la faisabilité technique, de la qualité obtenue et des contraintes du projet (voir section 10).

7 Architecture technique

L'architecture proposée organise le système en un pipeline en cinq grandes étapes : traitement du contenu source, compréhension multimodale, structuration du contenu, transformation (script, storyboard, visuels) et assemblage final.




FIGURE 1 – Architecture du pipeline de transformation

Cette architecture constitue un point de départ ; elle sera affinée au fil des phases de développement (voir section 13) en fonction des résultats obtenus lors du MVP.

8 Modèles de données

Trois structures intermédiaires principales sont définies afin de garantir la traçabilité de l'information entre les étapes du pipeline.

8.1 Scène (unité d'analyse de base)

```
{
  "id": "scene_001",
  "start": 125.4,
  "end": 138.7,
  "speaker": "speaker_1",
  "transcript": "...",
  "ocr_text": "...",
  "visual_description": "...",
  "topic": "...",
  "importance": 0.92
}
```

8.2 Chapitre

```
{
  "id": "chapter_03",
  "title": "Comment le systeme fonctionne",
  "start": 845,
  "end": 1120,
  "summary": "...",
  "key_points": ["...", "..."]
}
```

8.3 Scène transformée (storyboard)

```
{
  "scene_id": "scene_04",
  "chapter_id": "chapter_03",
  "duration": 8,
  "narration": "...",
  "visual_type": "animated_diagram",
  "visual_description": "...",
  "on_screen_text": "...",
  "transition": "fade"
}
```

Ces schémas pourront être enrichis en cours de développement (ex. ajout d'un champ de langue, d'un identifiant de locuteur normalisé, ou d'un score de confiance ASR).

9 Choix technologiques et justification

Les choix ci-dessous sont contraints par les hypothèses du projet (section 10) : absence d'accès GPU et budget quasi nul. Ils privilégient donc des solutions gratuites ou à quota gratuit généreux, exécutables en traitement différé (batch), sans exigence de temps réel.

TABLE 1: Stack technologique retenu

Étage du pipeline	Technologie retenue	Justification	Coût
Traitement vidéo / détection de scène	FFmpeg + PySceneDetect	Standard open-source, fonctionne entièrement sur CPU, aucune dépendance GPU	Gratuit
Transcription (ASR)	faster-whisper (local) ou API Groq Whisper	Meilleure qualité gratuite FR/EN ; l'API Groq évite la lenteur du traitement CPU	Gratuit (quota API)
Diarisation (identification des locuteurs)	WhisperX + pyannote-audio	Alignement mot-à-mot et séparation des locuteurs, compatible CPU en traitement différé	Gratuit
OCR des diapositives	Tesseract OCR	Suffisant pour extraire le texte des diapositives PowerPoint sur les frames clés	Gratuit
Compréhension / raisonnement (LLM)	Gemini Flash ou Groq (Llama 3.x), offres gratuites	Fenêtre de contexte très large (jusqu'à 1M tokens) permettant d'analyser un transcript complet sans découpage complexe	Gratuit (quota)
Détection sémantique des chapitres	Sentence-Transformers (all-MiniLM-L6-v2)	Modèle léger, exécutable sur CPU, efficace pour détecter les ruptures thématiques	Gratuit
Génération des visuels	Remotion (React + FFmpeg)	Génération programmatique et déterministe des visuels à partir du storyboard JSON ; contrôlable et explicable en soutenance	Gratuit
Narration (TTS)	edge-tts	Voix neurales gratuites de bonne qualité, support FR et EN, sans clé API	Gratuit
Assemblage final	FFmpeg / Remotion	Composition de la narration, des visuels et des transitions en un fichier vidéo final	Gratuit

10 Contraintes et hypothèses du projet

- Aucun accès GPU disponible : toutes les briques du pipeline doivent fonctionner sur CPU ou via des API cloud à quota gratuit.
- Budget quasi nul : priorité systématique aux outils open-source et aux offres gratuites ("free tier").
- Support bilingue requis : français et anglais, aussi bien pour la transcription que pour la génération du script et de la narration.
- Traitement en mode batch (différé) : aucune exigence de traitement en temps réel n'est imposée.
- Horizon de réalisation : l'ensemble du stage, avec une approche itérative (voir section 13).

11 Périmètre du MVP (Minimum Viable Product)

Le MVP doit démontrer le concept central du projet : enregistrement brut de formation → cours e-learning transformé complet → chapitres sémantiques. Il ne doit pas chercher à couvrir l'ensemble des fonctionnalités possibles dès la première itération.

1. Permettre le dépôt d'une vidéo.
2. Extraire l'audio de la vidéo.
3. Transcrire l'audio.
4. Détecter les locuteurs.
5. Analyser le contenu visuel.
6. Extraire le texte par OCR.
7. Construire une représentation multimodale du contenu.
8. Identifier les thèmes abordés.
9. Générer les chapitres.
10. Générer un script pédagogique nettoyé.
11. Générer un storyboard visuel.
12. Générer ou sélectionner les visuels correspondants.
13. Générer la narration audio si nécessaire.
14. Assembler la vidéo transformée.
15. Produire le cours transformé complet.
16. Associer les métadonnées de chapitrage au résultat final.

Les fonctionnalités avancées telles que les quiz automatiques ou le tuteur IA ne doivent pas être priorisées tant que ce pipeline central n'est pas fonctionnel et validé.

12 Critères d'évaluation et d'acceptation

Axe d'évaluation	Critères
Préservation du contenu	Les concepts importants sont-ils préservés ? Les détails techniques sont-ils exacts ? Les exemples et conclusions sont-ils conservés ?
Qualité de la transformation	Le résultat final ressemble-t-il à un véritable cours ? Les visuels sont-ils pertinents ? La narration est-elle cohérente ? La présentation est-elle professionnelle ?
Qualité du chapitrage	Les chapitres sont-ils logiquement séparés ? Les titres sont-ils pertinents ? Les timestamps sont-ils exacts ? La navigation est-elle facile pour l'apprenant ?
Expérience d'apprentissage	Le cours est-il plus facile à suivre que l'enregistrement brut ? L'apprenant comprend-il le contenu sans avoir vu la réunion originale ? Les visuels renforcent-ils l'explication ?

13 Gestion de projet et planification

Le stage étant fixé à une durée de deux mois (8 semaines), le développement doit être mené selon une démarche itérative permettant de livrer, à la fin de chaque itération, un incrément fonctionnel et démontrable du système — plutôt que de chercher à construire l'ensemble du pipeline en une seule fois.

13.1 Modèle de cycle de vie retenu

Le modèle retenu est un cycle de vie Agile itératif et incrémental, inspiré de Scrum et adapté à un stage individuel (un seul développeur, un encadrant jouant le rôle de Product Owner). Ce choix est justifié par la nature du projet :

- Le projet comporte une forte incertitude technique (qualité réelle de l’ASR en français, comportement des quotas API gratuits, qualité des visuels générés) qu’il est impossible de lever entièrement en amont.
- Chaque brique (transcription, chapitrage, script, visuels) doit être validée empiriquement avant de construire la suivante.
- Un cycle en V, où les exigences et l’architecture sont figées avant tout développement, est inadapté à ce contexte de recherche appliquée.

Le projet est donc découpé en 4 sprints de 2 semaines, précédés d’un court cadrage initial, avec une revue de sprint (démonstration à l’encadrant) et une rétrospective courte à la fin de chaque itération.

13.2 Découpage en sprints

Sprint	Semaines	Objectif du sprint	Livrable de fin de sprint
Sprint 1	S1 – S2	Cadrage, mise en place de l’environnement, pipeline d’ingestion (extraction audio, transcription ASR, OCR des diapositives, détection de scènes) et première représentation multimodale.	Pipeline d’analyse fonctionnel sur une vidéo de test, produisant des objets “scène” structurés.
Sprint 2	S3 – S4	Compréhension sémantique du contenu (prompt engineering LLM) et chapitrage automatique par détection de ruptures thématiques.	Chapitres générés automatiquement (titre, résumé, points clés) sur la vidéo de test.
Sprint 3	S5 – S6	Génération du script pédagogique, du storyboard visuel, prototypage des premiers visuels (Remotion) et de la narration (TTS).	Extrait de cours transformé (1 à 2 chapitres complets) avec narration et visuels.
Sprint 4	S7 – S8	Assemblage complet du cours, intégration du chapitrage, évaluation selon les critères de la section 12, corrections, rédaction du rapport et préparation de la soutenance.	MVP complet démontrable de bout en bout + rapport de stage + support de soutenance.

13.3 Planning prévisionnel

Vue d’ensemble du planning sur les huit semaines du stage (X = semaine d’activité principale) :

Tâche	S1	S2	S3	S4	S5	S6	S7	S8
Cadrage & setup environnement	X							
Ingestion : ASR, OCR, scènes	X	X						
Repr. multimodale + compréhension LLM		X	X					
Chapitrage sémantique automatique			X	X				
Génération du script pédagogique				X	X			
Storyboard visuel					X			
Génération des visuels (Remotion)					X	X		
Narration (TTS)						X		
Assemblage vidéo du cours complet						X	X	
Intégration du chapitrage final							X	
Évaluation, tests, corrections							X	X
Rédaction rapport & soutenance							X	X

13.4 Outils de pilotage et de suivi

Besoin	Outil retenu	Justification
Gestion du backlog et des tâches	GitHub Projects (tableau Kanban)	Gratuit, directement lié au dépôt de code, suffisant pour un stage individuel
Gestion de version du code	Git + GitHub	Traçabilité des évolutions, historique exploitable pour le rapport de stage, sauvegarde du travail
Suivi d'avancement	Journal de bord hebdomadaire (Notion ou fichier Markdown versionné)	Trace écrite des décisions techniques, des blocages et des résultats, réutilisable pour la rédaction du rapport final
Communication avec l'encadrant	Point hebdomadaire (15–30 min) + compte-rendu court	Validation régulière des orientations, détection précoce des écarts par rapport au planning
Documentation technique	README du dépôt + Notion (spécifications vivantes)	Documentation à jour, utile pour la soutenance et pour la maintenance future du système
Suivi qualité	Checklist basée sur les critères d'évaluation (section 12)	Vérifiée à la fin de chaque sprint pour objectiver l'avancement réel plutôt que perçu

13.5 Rituels de suivi

- **Sprint planning** : en début de sprint, définition des objectifs et découpage en tâches (30 min).
- **Revue quotidienne courte** : bilan personnel de 5 à 10 minutes consigné dans le journal de bord (avancement, blocages, prochaine action).
- **Sprint review** : démonstration du livrable à l'encadrant en fin de sprint sur la vidéo de test.
- **Rétrospective** : identification rapide de ce qui a bien fonctionné et de ce qui doit être ajusté pour le sprint suivant.

13.6 Gestion des risques

Risque	Impact	Mitigation
Qualité insuffisante de la transcription en français	Dégrade toute la chaîne (chapitrage, script)	Tester plusieurs modèles ASR dès le Sprint 1 sur un extrait réel avant de figer le choix
Quotas des API gratuites (LLM, ASR) insuffisants	Blocage du traitement en cours de sprint	Prévoir un repli local (faster-whisper local) et répartir les appels entre plusieurs fournisseurs
Complexité de la génération visuelle sous-estimée	Retard sur les Sprints 3–4	Démarrer par des visuels simples (texte animé, formes basiques) avant les diagrammes complexes
Retard cumulé sur un sprint	Risque de non-finalisation du MVP	Sprint 4 volontairement dimensionné comme buffer : priorité à la stabilisation plutôt qu'aux nouvelles fonctionnalités

14 Fonctionnalités futures (hors périmètre du MVP)

Les fonctionnalités suivantes sont identifiées comme pistes d'évolution possibles, mais ne font pas partie du périmètre initial du projet :

- Recherche interne dans le contenu du cours
- Sous-titres
- Génération automatique de quiz
- Génération de flashcards
- Tuteur IA conversationnel
- Suivi de la progression de l'apprenant

15 Glossaire

Terme	Définition
ASR	Automatic Speech Recognition — reconnaissance automatique de la parole, transformation de l'audio en texte
OCR	Optical Character Recognition — reconnaissance optique de caractères, extraction de texte depuis une image
TTS	Text-to-Speech — synthèse vocale, génération de voix à partir d'un texte
LLM	Large Language Model — modèle de langage de grande taille utilisé pour la compréhension et la génération de texte
Multimodal	Qui combine plusieurs types de données (audio, texte, image/vidéo) dans une même analyse
Storyboard	Plan de production détaillant, scène par scène, la narration et les éléments visuels à afficher
Chapitrage sémantique	Découpage d'un contenu en chapitres basé sur les changements de sujet plutôt que sur la durée
MVP	Minimum Viable Product — version minimale d'un système démontrant sa valeur fonctionnelle centrale
Diarisation	Identification et séparation des différents locuteurs au sein d'un enregistrement audio